

Exercícios

Disciplina: Inteligência Artificial

No clássico "Teste de Turing" (1950), qual é o principal critério utilizado para determinar se uma máquina pode ser considerada inteligente?

- A) Se a máquina for capaz de realizar cálculos matemáticos complexos mais rapidamente do que qualquer humano.
- B) Se a máquina possuir um corpo robótico capaz de se locomover em terrenos acidentados.
- C) Se a máquina conseguir convencer um juiz humano de que ela também é um ser humano durante uma conversa.
- D) Se a máquina for capaz de programar outros computadores sem auxílio externo.

O que diferencia fundamentalmente o paradigma do aprendizado de máquina do paradigma da programação clássica?

- A) A máquina descobre as regras (o programa) a partir dos dados, em vez de recebê-las prontas de um programador.
- B) O uso obrigatório de supercomputadores para qualquer tarefa simples.
- C) A impossibilidade de humanos entenderem como o código foi escrito.
- D) A exclusão de qualquer base matemática no desenvolvimento do sistema.

Diferentemente do Aprendizado Supervisionado, o Aprendizado por Reforço não utiliza rótulos. Como o sistema sabe que está progredindo (i.e., aprendendo) corretamente?

- A) Por meio de um sinal de recompensa numérica que o agente tenta maximizar ao longo do tempo.
- B) Ao comparar a sua saída com a resposta correta fornecida por um especialista humano em cada passo.
- C) Pela identificação espontânea de grupos de dados semelhantes sem qualquer orientação externa.
- D) Utilizando a força bruta para testar todas as combinações possíveis de código.

Qual o principal objetivo ao treinar um modelo de Machine Learning?

- A) Memorizar o banco de dados.
- B) Reduzir a necessidade de processamento de dados.
- C) Generalizar o conhecimento para tomar decisões sobre dados nunca vistos.
- D) Substituir a matemática por algoritmos simples.

No Aprendizado Supervisionado, o que representam as variáveis x e y na lógica $y = f(x)$?

- A) x é a resposta e y é o dado bruto.
- B) x são as características (features) e y é o rótulo (label/resposta).
- C) x e y são apenas coeficientes de erro.
- D) x é a recompensa e y é a ação do robô.

Para transformar uma tabela complexa de 100 colunas em um gráfico visual de 2D, usamos:

- A) Redução de dimensionalidade.
- B) Classificação supervisionada.
- C) Aprendizado por Reforço.
- D) Regressão Logística.

O material afirma que o objetivo do ML é a "Generalização". No contexto de um modelo preditivo, o que ocorreria se um sistema memorizasse perfeitamente todos os dados de treinamento, mas falhasse ao analisar dados novos?

- A) O sistema atingiu o objetivo de ML, pois provou ter aprendido os padrões fornecidos.
- B) O sistema falhou no objetivo de generalização, agindo mais como um banco de dados do que como uma inteligência artificial.
- C) O sistema demonstrou alta capacidade de Redução de Dimensionalidade.
- D) O sistema aplicou corretamente o aprendizado não-supervisionado, pois não dependeu de novas etiquetas.

A frase "Garbage in, Garbage out" é frequentemente citada no contexto de ciência de dados. Qual é a relação direta entre esse conceito e a etapa de EDA?

- A) A EDA serve apenas para criar visualizações bonitas para apresentações de negócios.
- B) A EDA é uma curadoria que garante que o modelo de ML não aprenda com dados ruidosos ou irrelevantes, o que degradaria as previsões.
- C) O princípio indica que, se a EDA for bem feita, o algoritmo de Machine Learning não precisa ser treinado.
- D) Significa que o "lixo" (dados ruins) deve ser mantido para que o modelo aprenda a lidar com os erros do mundo real.

Um analista está trabalhando com uma coluna que contém "Níveis de Febre" (Baixa, Média, Alta). Como essa variável deve ser classificada e qual a restrição matemática aplicada a ela?

- A) Qualitativa Nominal: operações aritméticas são permitidas.
- B) Quantitativa Discreta: apenas a contagem é permitida.
- C) Qualitativa Ordinal: existe uma hierarquia, mas operações aritméticas não são aplicáveis.
- D) Quantitativa Contínua: permite o cálculo da média e da variância.

Qual técnica de preenchimento de valores faltantes é aplicável tanto a variáveis numéricas quanto a categóricas?

- A) Mediana.
- B) Média.
- C) Moda.
- D) KNNImputer.

Durante a análise exploratória de dados, é comum identificar relações estatísticas entre pares de variáveis. No entanto, a interpretação dessas relações deve ser feita com cautela. Qual afirmação expressa corretamente esse cuidado conceitual?

- A) Uma correlação alta sempre indica que uma variável causa a outra.
- B) Correlação só existe entre variáveis categóricas.
- C) Correlação não implica causalidade.
- D) Se a correlação for zero, as variáveis são obrigatoriamente idênticas.

Um analista de dados está tratando valores faltantes em uma coluna numérica que representa o "Preço de Imóveis". Ao analisar o histograma, ele percebe uma longa cauda à direita, indicando a presença de mansões com valores extremamente elevados (outliers). Qual estratégia de imputação é a mais robusta para evitar distorções estatísticas nesse cenário?

- A) Preencher com a Média, pois ela utiliza todos os valores do conjunto de dados, garantindo que a variação total seja preservada.
- B) Preencher com a Moda, pois é a única métrica que pode ser aplicada tanto a variáveis numéricas quanto categóricas.
- C) Preencher com a mediana, pois ela é insensível a outliers e divide os dados em 50% acima e 50% abaixo, mantendo a representatividade central.
- D) Remover todas as linhas com valores faltantes, pois qualquer imputação em dados com outliers gerará um modelo enviesado.

Ao aplicar a Normalização (Min-Max Scaling) em um atributo que possui um único valor extremamente alto (um outlier discrepante), o que acontece com a distribuição dos demais valores "normais" após a transformação?

- A) Eles serão distribuídos uniformemente entre os valores -1 e 1.
- B) Eles permanecerão inalterados, pois a fórmula utiliza apenas a média dos dados.
- C) Eles serão "esmagados" para um intervalo muito pequeno próximo de zero, perdendo a distinção entre eles.
- D) Eles assumirão valores negativos, já que o outlier puxa o ponto central para cima.

Considere um atributo categórico "Cidade" com 500 nomes diferentes em um dataset de 1.000 linhas. Por que o One-Hot Encoding não seria a escolha ideal para codificar essa variável?

- A) Porque ele introduz uma ordem falsa entre as cidades, prejudicando modelos lineares.
- B) Porque ele gera alta dimensionalidade (muitas colunas), podendo causar a "maldição da dimensionalidade".
- C) Porque ele substitui o nome da cidade pela média do alvo, causando overfitting.
- D) Porque ele só funciona com categorias que possuem uma hierarquia clara.

Você tem um atributo categórico nominal de alta cardinalidade (muitas categorias) e um problema de regressão. Considerando desempenho e dimensionalidade, qual codificação é a mais adequada e qual risco principal deve ser gerenciado?

- A) One-Hot Encoding — risco: maldição da dimensionalidade.
- B) Label Encoding — risco: introduzir ordem falsa entre categorias.
- C) Target Encoding — risco: overfitting em categorias com poucos exemplos.
- D) Binary Encoding — risco: criar dependência linear que confunda árvores.

Em um conjunto assimétrico (distribuição com cauda longa) e com presença de outliers extremos, qual escalonador preserva melhor as relações entre os valores não discrepantes e por quê?

- A) Min-Max, porque restringe tudo a [0, 1] e destaca diferenças pequenas.
- B) StandardScaler, porque centraliza em média 0 e desvio padrão 1 e é imune a outliers.
- C) RobustScaler, porque usa a mediana e o IQR, minimizando a influência de outliers e mantendo as distâncias entre os valores não discrepantes.
- D) Nenhum. O correto é excluir outliers sempre antes do escalonamento.

Na regressão linear, é comum utilizarmos polinômios de graus variados para ajustar os dados. Considere a função-hipótese $h(x) = a_0 + a_1x + a_2x^2$. Embora o gráfico dessa função seja uma curva (uma parábola), este modelo ainda é classificado como "regressão linear". Qual é a justificativa técnica correta para essa classificação?

- A) O modelo é linear porque a variável x pode ser substituída por qualquer valor numérico linear.
- B) A linearidade refere-se à relação entre a saída e os pesos (parâmetros a), e não necessariamente em relação aos atributos de entrada x .
- C) O termo quadrático x^2 é desprezível para grandes conjuntos de dados, tornando a função essencialmente uma reta.
- D) O teorema de Stone-Weierstrass garante que toda função curva pode ser linearizada através da derivada.

A função de custo Erro Quadrático Médio (EQM ou MSE) é amplamente utilizada em problemas de regressão. Ao plotarmos o valor do EQM em função dos pesos do modelo, obtemos uma superfície de erro. Por que a propriedade de "convexidade" dessa superfície (formato de tigela) é fundamental para o sucesso do algoritmo do Gradiente Descendente?

- A) Ela garante que o passo de aprendizagem possa ser infinito sem causar divergência.
- B) Ela assegura que a função tenha múltiplos pontos de mínimo local, permitindo várias soluções válidas.
- C) Ela garante a existência de apenas um ponto de mínimo global, assegurando que o algoritmo convirja e não fique preso em mínimos locais subótimos.
- D) Ela elimina a necessidade de calcular a derivada da função de erro, simplificando o processo computacional.

O algoritmo do Gradiente Descendente atualiza os pesos iterativamente usando o gradiente da função de erro. Na equação de atualização, subtrai-se uma parcela proporcional ao gradiente do peso atual ($w_{\text{novo}} = w_{\text{antigo}} - \alpha * \text{gradiente}$). Por que a subtração é necessária em vez da adição?

- A) Porque o gradiente aponta para a direção de maior crescimento da função, e o objetivo é minimizar o erro, indo na direção oposta.
- B) Porque o valor do gradiente é sempre negativo, a subtração o torna positivo para incrementar os pesos.
- C) Para garantir que a magnitude dos pesos diminua com o tempo, evitando estouro de memória (overflow).
- D) A subtração serve apenas para normalizar os dados, não influenciando a direção da otimização.

A taxa de aprendizagem (learning rate, alpha) é um hiperparâmetro crítico no Gradiente Descendente. Imagine que você está treinando um modelo e observa que, a cada iteração, o erro não diminui, mas sim oscila drasticamente ou aumenta progressivamente (diverge). Qual é a causa mais provável para esse comportamento?

- A) A taxa de aprendizagem escolhida é muito pequena, fazendo o algoritmo progredir muito lentamente.
- B) O conjunto de dados possui poucos exemplos, causando underfitting imediato.
- C) A taxa de aprendizagem é excessivamente grande, fazendo com que o algoritmo "pule" o ponto de mínimo e se afaste dele.
- D) A função de erro utilizada não é diferenciável, impedindo o cálculo do gradiente.

Existem diferentes variações do Gradiente Descendente baseadas na quantidade de dados usados para calcular o gradiente a cada passo: Batch (Batelada), Estocástico (SGD) e Mini-batch. Qual das alternativas descreve corretamente uma vantagem do Gradiente Descendente Estocástico em comparação ao Batch?

- A) O Estocástico é mais preciso, pois usa todos os dados de uma vez para calcular a direção exata do mínimo global.
- B) O Estocástico é computacionalmente mais leve e rápido por iteração, pois usa apenas uma amostra para atualizar os pesos, embora a convergência seja mais ruidosa.
- C) O Estocástico garante que o erro diminua monotonicamente a cada iteração, sem flutuações.
- D) O Estocástico é o único método capaz de resolver a Equação Normal de forma analítica.

Considere o Teorema de Stone-Weierstrass no contexto da modelagem de dados. Ao utilizarmos um modelo de regressão polinomial da forma $\hat{y} = a_0 + a_1x + a_2x^2 + \dots + a_kx^k$, estamos essencialmente tentando aproximar uma função contínua desconhecida. Sob a ótica do aprendizado de máquina e da complexidade do modelo, qual é a principal implicação prática desse teorema ao aumentarmos arbitrariamente o grau k do polinômio?

- A) O aumento de k garante que o erro de validação diminuirá monotonicamente, pois o modelo se torna capaz de representar qualquer função linear.
- B) O teorema assegura que qualquer função contínua pode ser aproximada, mas o aumento excessivo de k confere flexibilidade demasiada, permitindo que o modelo capture o ruído estocástico dos dados (overfitting) e não apenas o padrão subjacente.
- C) Polinômios de grau elevado deixam de ser tratáveis via Regressão Linear, pois a relação entre a saída $\hat{y}$ e os coeficientes a deixa de ser linear, exigindo o uso de redes neurais.
- D) O teorema afirma que polinômios de grau ímpar convergem mais rápido para o mínimo global da função de custo do que polinômios de grau par.

Um sistema de análise de imagens médicas que deve identificar, em uma mesma radiografia, se há presença de "Pneumonia", "Fratura" e "Derrame Pleural" (podendo haver mais de um simultaneamente) é um exemplo de:

- A) Classificação binária simples.
- B) Classificação multiclasse single-label.
- C) Classificação multilabel.
- D) Regressão linear múltipla.

Um modelo de classificação apresenta um erro de treinamento extremamente baixo (próximo de zero), mas um erro de teste muito elevado ao lidar com dados inéditos. Esse fenômeno é conhecido como:

- A) Subajuste (underfitting), causado por uma fronteira de decisão muito simples.
- B) Convergência ideal, indicando que o modelo aprendeu perfeitamente os dados.
- C) Sobreajuste (overfitting), indicando que o modelo perdeu a capacidade de generalização por ser excessivamente flexível.
- D) Regularização excessiva, que impediu o modelo de ajustar os pesos corretamente.

Em uma aplicação de detecção de fraude bancária (classe positiva = "Fraude" e classe negativa = "Não Fraude"), o sistema retorna uma probabilidade de 0,65 para uma transação. Se o desenvolvedor configurar o limiar (threshold) de decisão para 0,70, qual será o destino dessa transação?

- A) Será classificada como "Fraude", pois está acima de 0,5.
- B) Será classificada como "Não Fraude", pois a probabilidade calculada é inferior ao limiar estabelecido.
- C) O modelo entrará em estado de indeterminação, pois 0,65 é um valor "médio".
- D) A transação será excluída automaticamente do banco de dados por segurança.

Ao treinar um modelo de Regressão Logística, utiliza-se a função de erro de Entropia Cruzada em vez do Erro Quadrático Médio (MSE). Qual é a principal razão matemática para essa escolha no processo de otimização?

- A) O MSE produz uma função de custo não convexa para a regressão logística, o que pode levar o Gradiente Descendente a convergir para mínimos locais.
- B) A função de Entropia Cruzada é linear, o que torna o cálculo do gradiente mais rápido do que no MSE.
- C) O MSE não pode ser utilizado com variáveis dependentes discretas, apenas com variáveis contínuas.
- D) A Entropia Cruzada garante que a acurácia do modelo seja sempre superior à obtida com o MSE durante a validação cruzada.

Na análise de uma matriz de confusão para um problema de classificação, o que a diagonal principal representa especificamente?

- A) O total de falsos positivos e falsos negativos.
- B) A quantidade de exemplos que o classificador "confundiu".
- C) O número de classificações corretas para cada classe.
- D) A soma total de exemplos pertencentes à classe positiva.

Em uma rede neural do tipo MLP, qual é o papel fundamental das camadas ocultas (escondidas) no processamento dos dados?

- A) Atuar apenas como um ponto de transferência direta de atributos sem realizar cálculos.
- B) Reduzir a dimensionalidade dos dados de entrada para que a camada de saída possa processá-los linearmente.
- C) Criar representações intermediárias e extrair características relevantes dos dados de entrada.
- D) Substituir a necessidade de funções de ativação, simplificando o modelo matemático.

O que define uma rede neural como "profunda" (Deep Neural Network)?

- A) A complexidade matemática da função de erro utilizada.
- B) A presença de duas ou mais camadas ocultas em sua arquitetura.
- C) O fato de a rede ser treinada com um volume massivo de dados (Big Data).
- D) A utilização de conexões recursivas onde a saída volta para a entrada.

O algoritmo de backpropagation (retropropagação) é essencial para o aprendizado das redes neurais. Em que princípio matemático ele se baseia primordialmente?

- A) Regra da Cadeia.
- B) Teorema de Pitágoras.
- C) Integração por Partes.
- D) Decomposição em Valores Singulares (SVD).

Durante o treinamento, a etapa "forward" (direta) consiste em:

- A) Atualizar os pesos sinápticos usando o gradiente descendente.
- B) Calcular o erro e propagá-lo da saída para a entrada.
- C) Apresentar as entradas e processar os dados através das camadas para gerar uma predição (i.e., saída).
- D) Reinicializar aleatoriamente todos os pesos e bias da rede.

Após a conclusão do treinamento de uma rede neural do tipo MLP, o modelo é capaz de receber novos dados e gerar previsões sem a necessidade de consultar os dados de treino originais. Do ponto de vista matemático e estrutural, onde fica "armazenado" o conhecimento que a rede adquiriu durante o processo de aprendizado?

A) Na função de ativação escolhida, que se adapta dinamicamente a cada nova entrada de dados.

B) No conjunto de rótulos (labels) que a rede memoriza durante as diversas épocas de treinamento.

C) Na configuração específica dos valores dos pesos sinápticos e dos termos de bias (vieses) ajustados.

D) No número de neurônios da camada de entrada, que armazena os padrões estatísticos dos dados.